Rapport

Autocomplétion et structures de données

Structures de données — IFT2015

Par

Prénom1 Nom1
Prénom2 Nom2

Présenté à

François Major

7 avril 2026

Université de Montréal

Répondez aux quatre questions ci-dessous.
Les réponses doivent utiliser une ***notation asymptotique précise (Big-O)***
et être accompagnées d'une justification claire.

Q1 — Invariants des structures de données (12 pts)

Pour chacune des trois structures de données utilisées dans ce projet, définissez les **invariants structurels** (propriétés qui doivent toujours être vraies) et expliquez comment les opérations principales maintiennent ces invariants.

1a. Table de fréquences (`HashMap`) (4 pts)

1b. Arbre de préfixes (`PrefixTrie`) (4 pts)

1c. Tas min (`PriorityQueue`) (4 pts)

Q2 — Complexité asymptotique de l'entraînement (12 pts)

Considérez un corpus contenant N tokens. Le vocabulaire a une taille V ($V \leq N$). La longueur moyenne des tokens est supposée constante.

Analysez la complexité de la méthode `train(List<List<String» sentences)` en décomposant chaque étape.

Variables à utiliser : N (tokens), V (vocabulaire).

2a. Construction de la table de fréquences (`unigrams`) (4 pts)

2b. Construction du trie (4 pts)

2c. Construction des tables bigrammes et trigrammes (4 pts)

Q3 — Complexité asymptotique des requêtes (10 pts)

Considérez une requête depuis un modèle déjà entraîné sur un vocabulaire de taille V. On demande les k meilleures suggestions pour un contexte donné. Le préfixe soumis à `complete` a une longueur L.

Variables à utiliser : V, k, L.

3a. `topK` via la table de fréquences (4 pts)

3b. `complete` via le trie (6 pts)

Exprimer la complexité en distinguant la phase de descente au préfixe et la phase de DFS + sélection top-k.

Q4 — Comparaison d'implémentations alternatives (6 pts)

Choisissez **une** des structures de données utilisées dans ce projet et comparez-la à une alternative plausible.

Exemples : trie vs tableau trié, tas min vs tri complet,
table de hachage vs arbre binaire de recherche équilibré.

Votre réponse doit inclure :

- une description des deux approches,
- la complexité des opérations principales pour chacune,
- une discussion sur l'utilisation mémoire,
- une conclusion sur le contexte où chaque approche serait préférable.

Bibliographie

Les références doivent être présentées selon le style **APA**.

Exemple :

— Goodrich, M. T., Tamassia, R., & Goldwasser, M. H. (2014). *Data structures and algorithms in Java* (6e éd.). Wiley.

Ajoutez ci-dessous toutes les sources utilisées :

—

—

—

—